



ANÁLISIS Y PREDICCIÓN DE RETRASO EN ENTREGAS

PROYECTO ANÁLISIS Y MACHINE LEARNING APLICADO A LOGÍSTICA
EXCEL- POWER BI- SQL- PYTHON

ALEJANDRO CHICHARRO GARCÍA



OBJETIVO DEL PROYECTO

El objetivo del proyecto es analizar qué factores están relacionados con los retrasos en las entregas y realizar un modelo que pueda predecir si un pedido llegará tarde o no.

DATOS

Se cuenta con una variable objetivo, “entrega_tarde” con valores 0 (si llega a tiempo) o 1 (si llega tarde).

El proyecto dispone de 3 tablas.

- PEDIDOS: id_pedido, id_cliente, id_producto, fecha de pedido y entrega, transportista, prioridad, stock, coste de envío, importe, estado de entrega, unidades, canal, distancia km, días prometidos, entrega tarde.
- CLIENTES: id_cliente, cliente, provincia, segmento, antigüedad, pedidos previos, ticket medio histórico, incidencias previas y canal de alta.
- PRODUCTOS: id_producto, producto, categoría, precio unitario, peso, frágil, y margen.

Las tablas se relacionan mediante id cliente e id producto, siendo pedidos la tabla principal.

LIMPIEZA Y PREPARACIÓN DE LOS DATOS

Antes de comenzar el análisis se llevó a cabo una limpieza y transformación de los datos para que tuviesen calidad y coherencia entre ellos.

Se eliminaron valores duplicados, se corrigieron valores negativos e incoherentes, se trataron los valores nulos, en algunos aplicando la mediana, se normalizaron las fechas, se revisó el tipo de dato. Por ejemplo, se eliminaron valores duplicados, se estableció la mediana en valores como la antigüedad, se corrigió el formato de los números decimales, se escribieron igual todas las categorías (sin espacios al final, con las mismas mayúsculas...)


id_cliente	cliente	provincia	segmento	antigüedad_meses	pedidos_previos	ticket_medio_historico	incidencias_previas	canal_alta
10001	Cliente 001	Barcelona	Particular	70	8	70.15	0	Comercial
10002	Cliente 002	Alicante	Pyme	58	17	160.36	0	Tienda
10003	Cliente 003	Bilbao	Particular	64	13	34.31	0	Tienda
10004	Cliente 004	Alicante	Particular	31	16	156.18	1	Tienda
10005	Cliente 005	Málaga	Pyme	72	5	148.36	2	Web
10006	Cliente 006	Barcelona	Pyme	23	18	176.82	1	Web
10007	Cliente 007	Bilbao	Pyme	47	14	140.29	0	Tienda
10008	Cliente 008	Zaragoza	Particular	24	21	59.98	1	Web
10009	Cliente 009	Málaga	Particular	61	11	188.72	0	Tienda
10010	Cliente 010	Sevilla	Empresa	17	15	95.17	0	Tienda
10011	Cliente 011	Valencia	Pyme	43	23	63.68	0	Comercial
10012	Cliente 012	Barcelona	Particular	63	1	72.23	1	Web
10013	Cliente 013	Sevilla	Particular	72	21	131.68	1	Web
10014	Cliente 014	Alicante	Particular	26	15	18	1	Tienda
10015	Cliente 015	Zaragoza	Pyme	58	16	86.88	0	Tienda
10016	Cliente 016	Valencia	Pyme	11	10	187.9	1	Tienda
10017	Cliente 017	Bilbao	Pyme	23	16	173.65	1	Web
10018	Cliente 018	Madrid	Pyme	23	17	143.54	0	Web
10019	Cliente 019	Zaragoza	Empresa	30	19	148.32	0	Comercial
10020	Cliente 020	Madrid	Particular	39	15	18	1	Tienda
10021	Cliente 021	Alicante	Particular	2	0	139.14	0	Tienda
10022	Cliente 022	Alicante	Particular	2	8	93.74	0	Tienda
10023	Cliente 023	Sevilla	Particular	25	0	112.99	0	Web
10024	Cliente 024	Madrid	Particular	35	10	18	0	Comercial
10025	Cliente 025	Barcelona	Empresa	45	11	147.75	1	Tienda
10026	Cliente 026	Sevilla	Particular	67	13	101.61	0	Tienda
10027	Cliente 027	Málaga	Pyme	14	12	146.02	0	Tienda
10028	Cliente 028	Málaga	Particular	72	4	43.21	0	Web
10029	Cliente 029	Alicante	Particular	38	10	42.05	0	Tienda
10030	Cliente 030	Bilbao	Pyme	2	7	161.2	0	Web
10031	Cliente 031	Valencia	Particular	5	29	141.71	2	Tienda
10032	Cliente 032	Málaga	Pyme	18	11	77.16	0	Comercial
10033	Cliente 033	Valencia	Particular	5	0	149.24	1	Web

ANÁLISIS EN EXCEL

Tras realizar la limpieza, se hizo un análisis exploratorio con Excel con tablas dinámicas, gráficos y segmentadores para así estudiar algún patrón inicial, como los retrasos por transportista, por provincia...

Provincia	Ticket medio his	Entregas tardías
Madrid	121,7608333	46
Valencia	116,0719444	89
Sevilla	114,8925714	62
Zaragoza	113,65	77
Bilbao	99,39730769	74
Málaga	96,06973684	93
Alicante	92,99941176	71
Barcelona	85,69647059	74
Total general	104,5155598	586

prioridad
Alta
Normal



Gracias a ello se identificaron algunos patrones que se estudiaron más adelante en Power BI y SQL.

ANÁLISIS POWER BI

Tras el análisis básico en Excel, gracias a Power BI se desarrolló un dashboard para ver los principales problemas en la logística y entregas tardías.



Así se concluía en este estudio que TransNova era el transporte que más porcentaje de pedidos tardíos entregaba, que Sevilla era la ciudad con menos retrasos, que moda y electrónica eran las categorías con mayor porcentaje de pedidos tardíos y deporte la que menor porcentaje presentaba y que las entregas con prioridad alta eran las que más se retrasaban en proporción.

Esto sirvió como referencia a la hora del posterior análisis en Python.

ANÁLISIS SQL

Tras analizar visualmente en Excel y Power BI, se siguió realizando el estudio de los motivos de las entregas tardías con distintas técnicas como subconsultas, join, group by, case when... Con algunas preguntas cómo:

¿Qué transportistas presentan mayor porcentaje de retrasos?

¿La prioridad tiene relación con las entregas tardías?

¿Qué provincias tienen mayor porcentaje de entregas tardías?

¿Hay alguna relación entre el nivel de stock y los retrasos?

¿Los clientes con más incidencias obtienen más retrasos?

Un ejemplo de consulta que se realizó fue:

```
select c.provincia, avg(pe.distancia_km) as distancia_media, sum(pe.entrega_tarde) as entregas_tardias, round(sum(pe.entrega_tarde)*100.0/count(pe.id_pedido),2) as porcentaje_tardes from ClientesRaw c inner join PedidosRaw pe on c.id_cliente = pe.id_cliente group by c.provincia order by porcentaje_tardes desc;
```

En cuanto a las conclusiones, coincidían con lo visto visualmente, TransNova era la que más retrasos tenía y Rapidex y GoPack las que presentaron mejores resultados. Sevilla es la provincia con menor porcentaje de retrasos, y la categoría deporte es la categoría que menor porcentaje de retrasos presenta.

PREPARACIÓN DE LOS DATOS EN PYTHON

En Python se unieron las tablas para tener una única tabla orientada al análisis y al desarrollo de un modelo predictivo. Tras ello, se transformaron y prepararon las variables que la componen.

- Se unificaron las tablas mediante id producto e id cliente.
- Se volvieron a revisar los tipos de datos y valores nulos, y por ejemplo se imputó la mediana en ticket medio histórico que a priori no se había imputado.
- Se convirtieron las fechas en día de la semana y número de mes para poder tratar con ellas y ver relaciones.
- Se eliminaron los identificadores y variables no necesarias para predecir.
- Se eliminó fecha de entrega real para no tener información verídica.
- Se separó entre variable objetivo (y) y variables explicativas (X), y tras ello se usó 75% para entrenamiento y el 25% para test.
- Se escalan las variables numéricas para no tener números muy dispersos con StandardScaler.
- Se codificaron las variables categóricas con OneHotEncoder.

COMPARACIÓN MODELOS PREDICTIVOS

Se realizaron 3 modelos predictivos para predecir si un envío llegaría tarde: Regresión Logística, Árbol de decisión y Random Forest, obteniéndose los siguientes resultados.

MODELO	ACCURACY	PRECISIÓN	RECALL	F1
Regresión Logística	0,71	0,73	0,65	0,69
Árbol de decisión	0,64	0,65	0,56	0,60
Random Forest	0,67	0,68	0,61	0,64

- Accuracy: es el porcentaje total de predicciones correctas.
- Precision: es el porcentaje de pedidos retrasados que acertó el modelo.
- Recall: de todos los pedidos que llegaron tarde, cuántos se consiguieron predecir.
- F1: equilibrio entre precisión y recall.

La regresión logística fue el modelo que mejor rendimiento dio en general en las medidas estudiadas, pero, sobre todo, la que permitió detectar una mayor proporción de retrasos reales, que es lo importante, no obtener más retrasos no previstos. Por este motivo, se decidió usar como modelo base.

Tras seleccionarla, se estudiaron las variables más importantes analizando sus coeficientes. Y se distinguieron en dos grupos.

- VARIABLES QUE AUMENTAN LA PROBABILIDAD DE RETRASO: Mayor distancia, TransNova, coste de envío, prioridad alta, electrónica, Madrid.
- VARIABLES AUMENTAN LA PROBABILIDAD DE LLEGAR A TIEMPO: Sevilla, deporte, Rapidex, más días prometidos, mayor importe del pedido.

Random Forest coincidía en la importancia de las variables distancia, coste de envío e importe.

Hay resultados que coinciden con el análisis descriptivo realizado, como Sevilla la provincia con menos retrasos, Rapidex el transporte y deporte la categoría, así como TransNova el transporte con más retrasos.

SELECCIÓN DEL UMBRAL

Ya elegido el modelo de Regresión Logística, se analizaron distintos umbrales para reducir los falsos negativos y así poder detectar más retrasos que luego sucederán.

UMBRAL	PRECISION	RECALL	F1	FALSOS NEGATIVOS
0,5	0,73	0,65	0,69	52
0,45	0,7	0,74	0,72	38
0,4	0,69	0,81	0,75	28

Por ello, se considera mejor el umbral 0,4 ya que aumenta el recall de 0,65 a 0,81, se detectan más retrasos en las entregas y los falsos negativos se redujeron de 52 a 28. Esto supuso una pequeña reducción en la precisión, pero el F1 también subió e indica un equilibrio entre precisión y recall. Se elige este umbral ya que en logística lo principal es anticipar posibles retrasos.

CONCLUSIONES

La regresión logística fue el mejor modelo para predecir, y dentro de ella, ajustar el umbral a 0,4 permitió reducir los falsos negativos.

Las variables relacionadas con distancia, transportista, coste de envío, prioridad, provincia y categoría tienen influencia.

Algunas observaciones vistas con Power BI y SQL se mantuvieron en el análisis predictivo como el caso del mal comportamiento de TransNova, y el buen comportamiento de Sevilla, Rapidex...

Para una mejora, debería haber una revisión del transportista, planificarlo mejor o realizar mayor seguimiento para no tener retrasos imprevistos. Quizás estas conclusiones cambiarían si se tuviesen en cuenta otras variables como el clima, el tráfico, vacaciones...